


# AUC - ROC Curve

В машинном обучении измерение производительности является важной задачей. Поэтому, когда дело доходит до проблемы классификации, мы можем рассчитывать на кривую AUC-ROC. Когда нам нужно проверить или визуализировать производительность задачи классификации нескольких классов, мы используем кривую AUC (площадь под кривой) ROC (рабочие характеристики приемника). Это один из наиболее важных показателей оценки и для проверки производительности любой модели классификации. Он также записывается как AUROC (площадь под рабочими характеристиками приемника).

## Что такое кривая AUC-ROC?

Кривая AUC - ROC представляет собой измерение производительности для задач классификации при различных пороговых значениях. ROC представляет собой кривую вероятности, а AUC представляет собой степень или меру разделимости. Он говорит, насколько модель способна различать классы. Чем выше AUC, тем лучше модель предсказывает 0 классов как 0 и 1 класс как 1. По аналогии, чем выше AUC, тем лучше модель различает пациентов с заболеванием и без заболевания.

Кривая ROC построена с TPR в зависимости от FPR, где TPR находится на оси y, а FPR — на оси x.



**Определение терминов, используемых в AUC и ROC Curve.**

TPR (True Positive Rate) / Recall / Sensitivity

$$\text{TPR / Recall / Sensitivity} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Specificity

$$\text{Specificity} = \frac{TN}{TN + FP}$$

FPR

$$\begin{aligned} \text{FPR} &= 1 - \text{Specificity} \\ &= \frac{FP}{TN + FP} \end{aligned}$$


**Как рассуждать о производительности модели?**

Отличная модель имеет AUC, близкую к 1, что означает хорошую степень разделимости. Плохая модель имеет AUC около 0, что означает, что она имеет наихудший показатель разделимости. На самом деле, это означает, что он отвечает взаимностью на результат. Он предсказывает 0s как 1s и 1s как 0s. И когда AUC равен 0,5, это означает, что модель вообще не имеет возможности разделения классов.


Давайте интерпретируем приведенные выше утверждения.

Как известно, ROC — это кривая вероятности. Итак, давайте построим распределения этих вероятностей:


Примечание. Красная кривая распределения относится к положительному классу (пациенты с заболеванием), а зеленая кривая распределения относится к отрицательному классу (пациенты без заболевания).




Это идеальная ситуация. Когда две кривые вообще не перекрываются, это означает, что модель имеет идеальную меру разделимости. Он прекрасно способен различать положительный класс и отрицательный класс.



Когда два распределения перекрываются, мы вносим ошибки типа 1 и типа 2. В зависимости от порога мы можем минимизировать или максимизировать их. Когда AUC равен 0,7, это означает, что вероятность того, что модель сможет различить положительный класс и отрицательный класс, составляет 70%.



Это худшая ситуация. Когда AUC составляет приблизительно 0,5, модель не имеет возможности различать положительный класс и отрицательный класс.



Когда AUC приблизительно равен 0, модель фактически отвечает взаимно стью на классы. Это означает, что модель предсказывает отрицательный класс как положительный класс и наоборот.

Чувствительность и специфичность обратно пропорциональны друг другу. Таким образом, когда мы увеличиваем чувствительность, специфичность уменьшается, и наоборот.

Когда мы уменьшаем порог, мы получаем больше положительных значений, что увеличивает чувствительность и снижает специфичность.

Точно так же, когда мы увеличиваем порог, мы получаем больше отрицательных значений, таким образом, мы получаем более высокую специфичность и более низкую чувствительность.

Как мы знаем, FPR равен 1 - специфичности. Таким образом, когда мы увеличиваем TPR, FPR также увеличивается, и наоборот.